Entrega 2
Giordano Fraga, Gabriel Pivotto, Pedro Duarte, Caio Adriano, Lucas Chagas

Para essa entrega, primeiramente vimos todos os diferentes datasets que tínhamos coletados e fizemos uma etapa de escolha dentre todos os datasets que pegamos para selecionar quais realmente iríamos usar. Após a corta de aproximadamente metade dos datasets coletados, que acreditamos que não seriam muito úteis ao tema que estamos vendo, ou simplesmente difíceis de usar, acabamos com os seguintes restando:

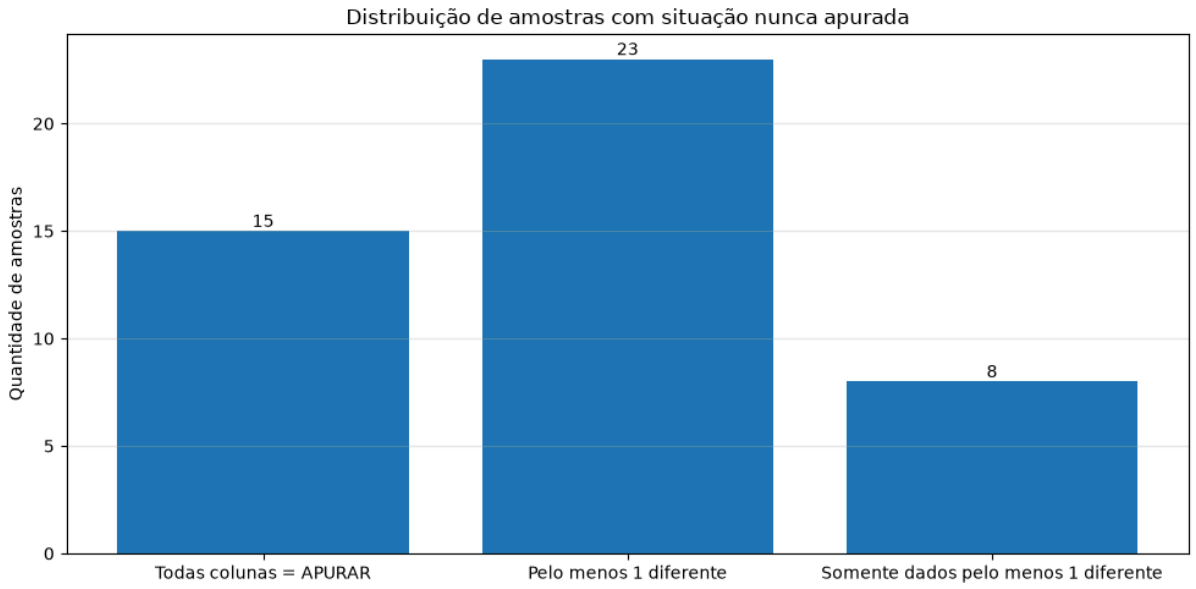
- **rmpa_crise_sb_ebaps{data}:** situação das estações de bombeamento de água Pluvial na RMPA;
- **rs_crise_abrigos{data}{hora}:** pontos de abrigos de voluntários e doações;
- **rs_crise_patrimonio_cultural:** instituições do patrimônio cultural e acervos atingidos.
- **atlas_digital_filtrado:** mostra registros de diferentes eventos meteorológico e hidrologico e seus efeitos (danos humanos, municipais, ambientais, etc..)
- **data (INCT):** os dados disponibilizados pela INCT

Depois de selecionar os Datasets, fizemos a criação de um esboço das duas telas no figma, servindo para só prototipar quais dados iríamos usar e como. O figma pode ser encontrado no link seguinte:

- https://www.figma.com/design/DxiyBK5EE2tqu7YBxB2NIt/dashboard-prototipo?node-id=0-1&t=rN7NAqulmOHCzHLP-1

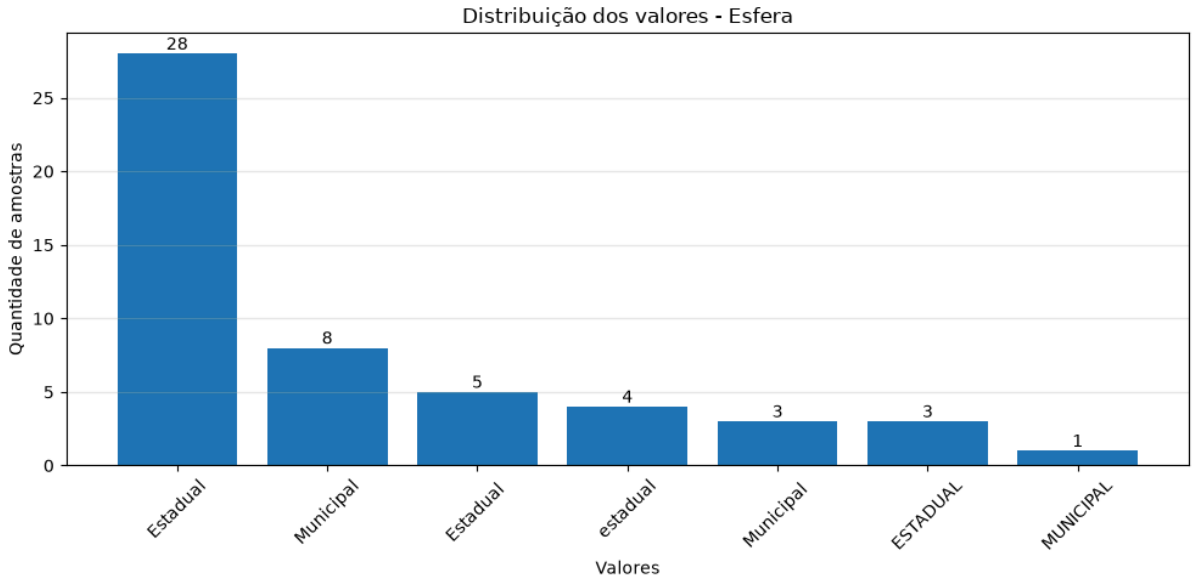
Logo, criamos notebooks EDA em nossos dataset para entender e explorar os dados e suas relações. Os seguintes gráficos foram gerados:

DATASET: **rmpa_crise_sb_ebaps_{data}**



Após usar um gráfico de barra, é possível ver que 15 amostras sobre o estado das estações de bombeamento não foram apuradas, tendo em todas as colunas de **Situ_{data}** apenas o valor “APURAR”.

DATASET: **rs_crise_patrimonio_cultural**



Usando um gráfico de barra, foi analisado a coluna “Esfera” e percebeu-se que a nomenclatura das classificações se mostrou inconsistente, apresentando várias formas de escrita para um mesmo valor

Para a limpeza dos dados, fizemos as seguintes coisas:

- **rmpa_crise_sb_ebaps{data}:** primeiramente, as colunas “Endereco”, “ID” , “nome_1”, “SG_MUN”, “NM_MUN”, “Latitude” e “Longitude” foram removidas pois não teriam uso para o que planejamos. Segundamente, foi percebido que várias estações de bombeamento sendo rastreadas por esse dataset simplesmente nunca mudaram do estado de “APURAR” e logo então não são úteis para nossa visualização, foi retirada as linhas no qual o estado da estação simplesmente nunca mudava. Por último, também se percebe que existe vários dias onde a coluna do estado está como “APURAR” para todas as estações, mesmo as que estavam ligadas antes e continuaram ligados após esse dia, provavelmente causado por algum erro no sistema que estava verificando o status delas, logo então, as colunas (dias) onde todas as estações estavam fazendo nada também foram removidas.

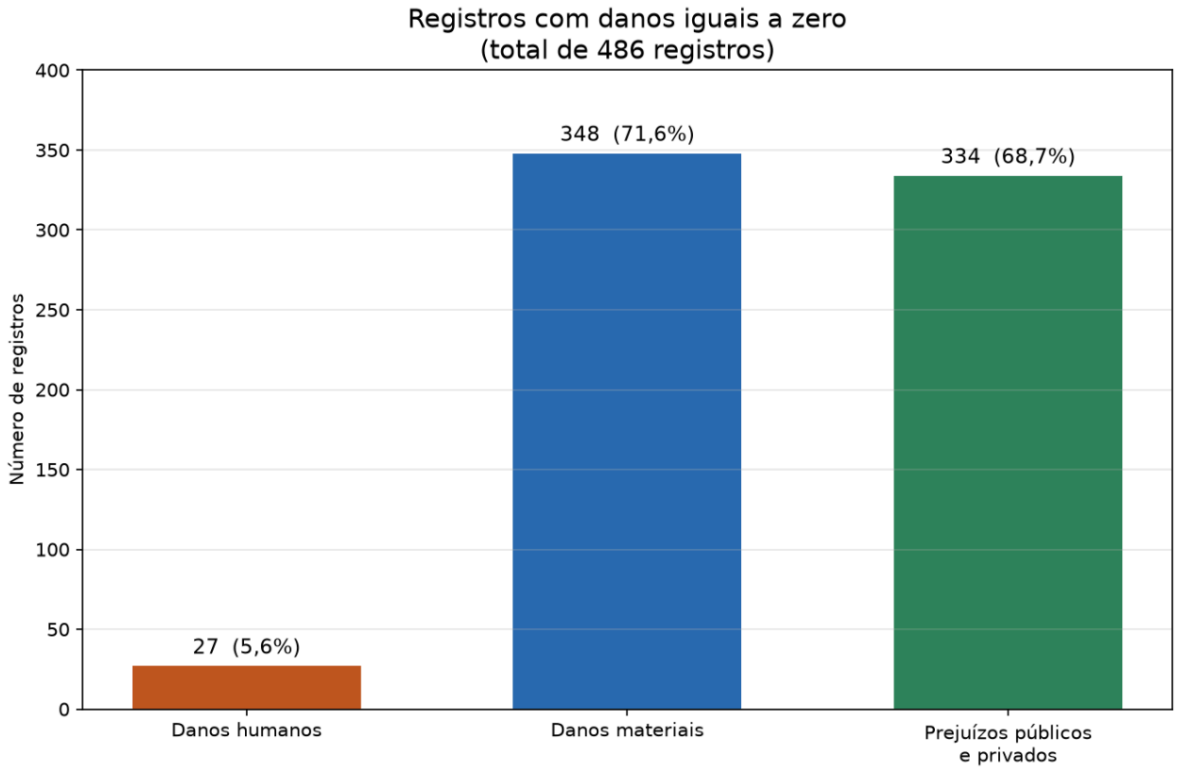
- **rs_crise_abrigos{data}{hora}:** o principal problema deste conjunto de dados era o fato dela ter várias instâncias em datas diferentes, onde a camada tinha um padrão diferente, seja na nomenclatura dos atributos, ou na falta/adição de outras colunas. Logo, para simplificar o processo, foi usado somente 3 colunas deste dataset inteiro, sendo eles: “nome” (nome do abrigo), “tipo”

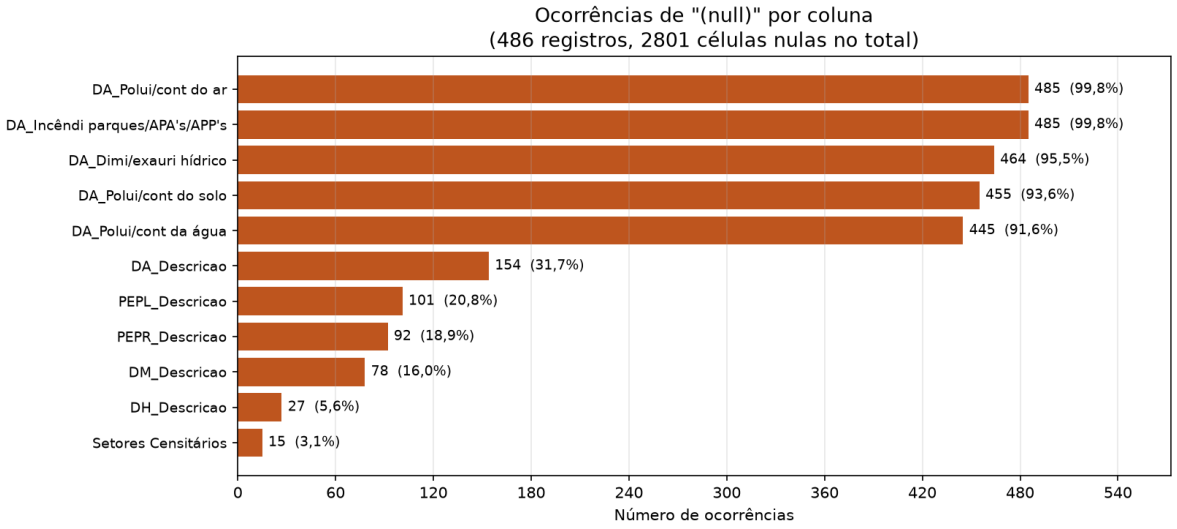
(tipo do abrigo) e “data” (coluna criada na qual apresenta a data que aquele dado foi retirado, gerado a partir do pós-fixo no nome da camada”). Além disso, foi ignorado atualização das amostras (pois nomes se repetiam nas diferentes instâncias) caso algum valor fosse nulo ou que tivesse “(a confirmar)” no texto.

- **rs_crise_patrimonio_cultural:** Primeiramente, é removido todas as instâncias que não possuem uma entrada na coluna NomeInstituicao. Depois, são removidas as colunas ID, X, Y, NomeCidade e Endereco. Para o restante das entradas, é feita uma pipeline de normalização dos nomes: para NomeInstituicao, primeiro normaliza o whitespace (remove espaços adicionais), depois converte os nomes em Titlecase, menos as siglas e palavras de conexão. Para a Esfera, normaliza o whitespace e capitaliza. Por fim, ele transforma os pontos em well-known-binary para comparar e remover duplicatas iguais.

- **atlas_digital_filtrado:** o dataset original do Atlas Digital de Desastres é extenso, tendo que ser cortado apenas para o período e região relevantes (de 21 de abril de 2024 a 30 de maio de 2024, no estado do RS). Foram substituídos valores vazios pela string “(null)”, presentes principalmente nas colunas de descrições de danos e danos ambientais (“[...]_Descricao” e “DA_[...]”, respectivamente) - embora alguns valores de Setores Censitários também tenham sido detectados. Deve ser considerado que múltiplos registros constam apenas com danos humanos, conforme indicado pelo primeiro gráfico abaixo. Em questão dos campos “(null)”, observável no segundo gráfico, maioria das colunas que apresentam essa string não serão utilizados no dashboard final - no entanto, os quinze registros de Sensores

Censitários podem afetar uma representação gráfica posteriormente.





- **data (INCT):** O dataset original formatado hierarquicamente por bairro, assim cada bairro tem seu conjuntos de atributos: ***affected_buildings, affected_population, population, total_buildings***. As principais mudanças no conjunto desses bairros são a remoção do atributo percentage, mudança de tipo no ***affected_population***, onde cada chave-valor corresponde qual nível houve aumento ou diminuição de populações afetadas nele, junto com o

respectivo valor da quantidade de afetados, e ***affected_buildings*** se tornou uma lista correlacionada com ***affected_population***, onde cada adição no atributo ***affected_population***, é adicionado valor no ***affected_buildings*** a Também foram produzidos dois gráficos para Análise e Exploração dos Dados (EDA), esses são População total afetada X Nível da água, e Top 10 bairros com prédios mais afetados.

